Introducción

El sector agroalimentario en México enfrenta desafíos estructurales de gran magnitud, entre los cuales destacan la variabilidad climática global, las alteraciones drásticas en los patrones hídricos y térmicos estacionales, así como los márgenes de productividad cada vez más ajustados que ponen en riesgo la estabilidad de los productores. En cultivos destinados al sector alimentario y la economía regional, como la cebada cultivada en los estados de Hidalgo, Tlaxcala y Puebla, la falta de información oportuna, transparente y verificable sobre el rendimiento real de las cosechas representa uno de los principales obstáculos operativos y comerciales. Esta brecha de información impacta de manera directa y negativa en la inclusión financiera de la población rural, ya que restringe la capacidad de las instituciones de banca de desarrollo, comercial y las empresas aseguradoras para evaluar los riesgos agropecuarios, encareciendo el acceso a servicios financieros adaptados a la realidad productiva de cada región agrícola.

Frente a esta problemática, la iniciativa promovida por los Fideicomisos Instituidos en Relación con la Agricultura (FIRA) a través del programa de Apoyo a la Innovación Tecnológica en el marco de la INdustria 4.0, impulsa la adopción de herramientas avanzadas de observación remota y ciencia de datos aplicada al campo. Las plataformas actuales proporcionan observaciones multiespectrales frecuentes, estandarizadas y de gran cobertura espacial, permitiendo monitorear de manera continua el desarrollo de la biomasa agrícola en tiempo real. No obstante el verdadero valor estratégico de estas tecnologías no reside únicamente en la adquisición masiva de imágenes, sino en la capacidad para desarrollar modelos analiticos e inteligencias predivtivas capaces de traducir series temporales de índices vegetativos, regímenes de precipitación y temperaturas en estimaciones cuantitativas altamente confiables del rendimiento por hectárea antes del periodo de cosecha.

El presente reporte técnico documenta de manera detallada y exhaustiva el proceso de diseño, validación y despliegue del modelo predictivo desarrollado en el marco del Reto AgroCebada 2026. A partir de un conjunto de datos integrados de 197 parcelas agrícolas, compuesto por 138 parcelas de entrenamiento y 59 parcelas reservadas exclusivamente para la evaluación, se diseñó un enfoque analítico híbrido e innovador que fusiona la zonificación agroclimática con técnicas de regresión lineal regularizada. El objetivo central de esta solución integral es mitigar eficazmente la asimetría informativa en toda la cadena de valor agrícola, proveyendo un instrumento cuantitativo robusto, auditable y listo para su integración en herramientas tecnológicas operativas y tableros web de consulta interactiva que beneficien directamente tanto a los pequeños productores como a los tomadores de decisiones estratégicas del sector agropecuario nacional.

Justificación

La disponibilidad masiva de datos procedentes de satélites y de estudios medioambientales ofrece una oportunidad real para transformar la gestión del rendimiento agrícola del campo mexicano. No obstante, para que este tipo de herramientas aporten valor, deben complementarse con modelos confiables que permitan extraer conclusiones fiables a partir de grandes volúmenes de datos disponibles.

El sector de la cebada en Hidalgo, Tlaxcala y Puebla, podría ser uno de los primeros en beneficiarse de esta previsibilidad. Ya que los rendimientos previsibles constituyen un

instrumento poderoso para los bancos de desarrollo rural, y FIRA desempeña un papel de liderazgo hacia la reducción de la asimetría de información que afecta actualmente a este sector.

Objetivo general

Desarrollar un modelo analítico, basado en técnicas de Aprendizaje Automático, capaz de predecir en tiempo real el rendimiento agrícola de las parcelas de cebada en los estados de Hidalgo, Tlaxcala y Puebla utilizando datos normales y de percepción remota sobre el estado de la vegetación, e integrarlo en una herramienta tecnológica operativa que permita su observación y consulta.

Objetivos específicos

- Realizar un análisis exploratorio de las variables disponibles (índice de vegetación, precipitaciones, temperatura y rendimiento observado) con el fin de detectar patrones y correlaciones clave.
- Entrenar y validar modelos predictivos (regresión lineal regularizada y algoritmos basados en árboles), seleccionando el mejor modelo mediante la comparación de sus estadísticos (RMSE, error absoluto medio, coeficiente de determinación, etc.) y predicción del rendimiento de las parcelas cuyos datos se han reservado para las pruebas de evaluación (30 % de las parcelas) utilizando el mejor modelo.
- Diseñar y desarrollar una aplicación o página web para consultar y visualizar los resultados de las predicciones por parcela.

Metodología

El desarrollo siguió el marco CRISP-DM (Chapman et al., 1999), organizando el proyecto en seis fases iterativas, descritas a continuación.

I. Comprensión del problema

El objetivo fue estimar el rendimiento de cebada (t/ha) de 59 parcelas, usando 138 parcelas con rendimiento conocido del ciclo abril-octubre de 2025, por lo que el análisis se limitó a ese periodo de tiempo. Además, se priorizó un modelo explicable y reproducible para la resolución del problema.

II. Comprensión de los datos

El entrenamiento del modelo y la creación de variables se limitó únicamente a los datos incluídos en los datasets otorgados por *FIRA*. Se integraron imágenes del satélite Planet (2025; NDVI, EVI, LAI y MSAVI), precipitación mensual de CHIRPS, temperaturas mínima y máxima de CHIRTS-ERA5, y elevación y pendiente (INEGI, 2025).

El máximo de los índices de vegetación correlacionó débil y negativamente con el rendimiento (r entre −0.17 y −0.26). El clima mostró asociaciones más fuertes: temperatura mínima (r = 0.60), precipitación (r = −0.46) y temperatura máxima (r = −0.29); la topografía alcanzó r = 0.29 y el área de la parcela no mostró relación.

III. Preparación de los datos

Se excluyeron las observaciones satelitales con más de 10% de nubosidad (conservando 31,708 de 47,804 registros). El clima se resumió para el ciclo (abril a octubre de 2025) y la topografía se extrajo por parcela. Dado que el máximo del índice resultó poco informativo, el NDVI se agregó por etapas fenológicas, además de la caída entre el máximo y octubre como indicadores de senescencia. Se descartaron variables redundantes o no discriminantes, como el día de arranque, la amplitud térmica, EVI, LAI y MSAVI, con lo que resultó una fila por parcela y nueve variables candidatas.

Feature	**Correlación con rendimiento**
tmin_ciclo	+0.60
prec_ciclo_mm	-0.46
tmax_ciclo	-0.29
elevacion_m	+0.29
pendiente_grados	+0.29
ndvi_may_jun	+0.53
ndvi_jul_sep	-0.28
ndvi_oct	+0.41
caida_pico_oct	-0.50

IV. Modelado

Se compararon un modelo ingenuo (promedio), la regresión Ridge (Hoerl y Kennard, 1970), que penaliza coeficientes extremos ante variables correlacionadas, y Random Forest (Breiman, 2001), con cuatro combinaciones de variables. La evaluación empleó validación cruzada (cinco particiones, tres repeticiones) y otra agrupada por zona de clima, que estima el desempeño en ubicaciones no observadas. Ridge igualó a Random Forest en la primera (error cuadrático medio, RMSE, de 0.55 t/ha), y generalizó mejor en zonas nuevas (0.64 frente a 0.88), por lo que se descartó este último.

El análisis reveló que las parcelas de entrenamiento se agrupan en solo 23 zonas de clima, pues varias comparten un píxel de ~5 km, y que estas zonas explican gran parte de la variación: el promedio de las demás parcelas de una zona alcanzó un error de 0.52 t/ha, mientras que, dentro de cada zona, los índices satelitales apenas se correlacionaron con el rendimiento. Este hallazgo motivó a una nueva iteración de comprensión de los datos, y adoptar un modelo híbrido: la predicción es el promedio del rendimiento de las parcelas de entrenamiento de la misma zona, suavizado hacia el promedio general, y, si la zona carece de datos, se emplea Ridge con las nueve variables. Una variante de ajuste adicional por parcela mejoró el error 0.01 t/ha, diferencia no distinguible del ruido, por lo que se prefirió la más simple.

V. Evaluación

El modelo final obtuvo un RMSE de 0.54 t/ha y un error absoluto medio de 0.39 t/ha en validación cruzada, frente a 0.85 t/ha del modelo ingenuo. De las 59 parcelas, 57 pertenecen a zonas con datos de entrenamiento y 2 recurren al respaldo Ridge; 7 (incluídas las Ridge) tienen baja confiabilidad por contar con una o ninguna parcela de entrenamiento en su zona. Entre estas limitaciones destacan el uso de un solo ciclo agrícola, que impide capturar variabilidad entre años; que parcelas de una misma zona reciben la misma predicción; y que, al elegir entre alternativas con los mismos datos, el error real podría superar al estimado. Las relaciones halladas son asociaciones, no causales.

VI. Despliegue

Se generó el archivo de predicciones, indicando el método y las parcelas de entrenamiento que respaldan cada estimación, y se guardó el modelo en su respectivo joblib.

Resultados y discusión

A partir del análisis de las 197 parcelas, el modelo generado permite identificar las relaciones que existen entre las condiciones climáticas, la vegetación y el estado de las cebadas. Después de la aplicación de un filtro de nubosidad menor o igual al 10% se conservan un total de 31,708 registros satelitales. Dentro de estos registros la variable que presentó mayor correlación positiva con el rendimiento fue la temperatura mínima teniendo una r=0.60 seguida del NDVI de mayo-junio teniendo una r=0.53 y finalmente notado que la precipitación aculuada poseia una correlación negativa de r=-0.46.

Para continuar con el análisis a fondo de estos datos se usaron los modelos de Rigde y Random forest, la comparación entre estos modelos mostró que el desempeño tenía una gran dependencia con respecto a la distribución de las parcelas entre las zonas climáticas. En la validación aleatoria, los dos modelos obtuvieron resultados similares (RMSE de 0.553 y 0.555) pero a la hora de realizar una validación por zonas el modelo de Ridge presentó un mejor desempeño.

El modelo final resultó con un desempeño aproximado de 0.4 t/ha de error absoluto medio (MAE), 0.54 t/ha de raíz de error cuadrático medio (RMSE) y un coeficiente de determinación (R^2) cercano a 0.55. El promedio que fue a arrojado por el modelo fue de 3.95 t/ha

Aplicando filtro de nubosidad <= 10
De 47,804 filas originales del PRO, quedan 31,708
Ninguna de las 197 parcelas se queda sin datos, en promedio tienen 161 observaciones
*Hay meses con más observaciones (marzo, abril) y meses con bastantes menos (junio), hay que definir si vamos a usar una ventana de tiempo más específica.

CONSTRUCCIÓN DEL DATASET FINAL + PREPARACIÓN DE DATOS
***** Los datos de 2022-2024 no se usan
* el rendimiento corresponde al ciclo abril-octubre 2025, solo usamos ese periodo
* Va a ser de 1 fila por parcela, con varias features

* Columnas de identificación: ID_POLIGONO, CONJUNTO (ENTRENAMIENTO/PREDICCION) y RENDIMIENTO_T_HA (la variable objetivo, en t/ha).

Variables candidatas a usar para el modelo

Feature	Cómo se calculó	Qué significa	Correlación con rendimiento
tmin_ciclo	Promedio de Tmin mensual, abr-oct 2025	Qué tan frías fueron las noches. Noches más cálidas se asocian con mayor rendimiento	+0.60
prec_ciclo_mm	Suma de la precipitación mensual, abr-oct 2025	Lluvia total del ciclo en mm. Más lluvia se asocia con menor rendimiento	-0.46
tmax_ciclo	Promedio de la Tmax mensual, arb-oct 2025	Qué tan calientes fueron los días	-0.29
elevacion_m	Valor del raster INEGI en la parcela	Altitud de la parcela, metros sobre el mar	+0.29
pendiente_grados	Pendiente	Inclinación del terreno en grados	+0.29
ndvi_may_jun	Promedio del NDVI mensual de mayo y junio	Qué tan verde está la parcela al arranque del cultivo. Mayor vigor temprano se asocia con mayor rendimiento	+0.53
ndvi_jul_sep	Promedio del NDVI mensual julio-sep	Vigor en la parte media del ciclo	-0.28
ndvi_oct	NDVI mensual oct	Qué tan verde sigue la parcela al final del ciclo. Se mantiene verde más tiempo en parcelas con mayor rendimiento	+0.41
caida_pico_oct	NDVI pico (max abr-oct) menos ndvi_oct	Qué tan rápido se acaba el cultivo después de su máximo. Una caída grande se asocia con menor rendimiento	-0.50

Variables descartadas

- ndvi_pico (max ndvi abr-oct): correlación débil con rendimiento
- ndvi_media_ciclo (promedio ndvi mensual abr-oct): sin aporte propio
- dia_arranque (primer día ndvi >= 0.35): no distingue parcelas
- area_ha: correlación -0.08
- EVI, LAI, MSAVI: muy correlacionados con NDVI (multicolinealidad)

Con todo eso vemos **<u>correlaciones entre variables para ver cuáles sacar</u>**:

Correlaciones (solo entrenamiento):

	elevacion_m	pendiente_grados	prec_ciclo_mm	tmin_ciclo	...	ndvi_jul_sep	ndvi_oct	caida_pico_oct	RENDIMIENTO_T_HA
elevacion_m	1.00	0.47	0.02	0.25	...	−0.09	0.36	−0.25	0.29
pendiente_grados	0.47	1.00	−0.12	0.06	...	−0.11	0.21	−0.20	0.29
prec_ciclo_mm	0.02	−0.12	1.00	−0.18	...	0.15	−0.30	0.38	−0.46
tmin_ciclo	0.25	0.06	−0.18	1.00	...	−0.40	0.32	−0.44	0.60
tmax_ciclo	−0.66	−0.43	0.07	0.06	...	−0.01	−0.45	0.27	−0.29
ndvi_may_jun	−0.05	0.15	−0.36	0.41	...	0.06	0.39	−0.37	0.53
ndvi_jul_sep	−0.09	−0.11	0.15	−0.40	...	1.00	−0.16	0.62	−0.28
ndvi_oct	0.36	0.21	−0.30	0.32	...	−0.16	1.00	−0.78	0.41
caida_pico_oct	−0.25	−0.20	0.38	−0.44	...	0.62	−0.78	1.00	−0.50
RENDIMIENTO_T_HA	0.29	0.29	−0.46	0.60	...	−0.28	0.41	−0.50	1.00

- tmax_ciclo y elevacion_m correlacionan -0.66. A mayor altitud, días menos calurosos. Casi la mitad de la información de tmax_ciclo ya viene en la elevación, y tmax solo tiene -0.29 con el rendimiento. Es la primera candidata a sacar.
- ndvi_oct y caida_pico_oct correlacionan -0.78. Casi son la misma variable.Solo se quedará una o ninguna
- tmin_ciclo correlaciona -0.44 con caida_pico_oct y -0.40 con ndvi_jul_sep. Parte de la señal del satélite en la segunda mitad del ciclo refleja el clima.

SELECCIÓN DE VARIABLES Y MODELO DE REFERENCIA

Hasta ahora tenemos correlaciones.

Hacer un modelo de referencia nos permite → medir error y comparar conjuntos de variables

2 modelos simples, +1 “ingenuo” que aplica promedios para comparar

1. Random Forest
2. Ridge (más simple)

4 sets para comparar variables:

A. clima + topografía
B. solo satélite
C. todas las 9 variables candidatas
D. set reducido (sin tmax_ciclo y ndvi_oct, que son las redundantes)

Resultados:

*RMSE (Raíz del Error Cuadrático Medio): medida estadística que calcula la diferencia promedio entre los valores predichos por un modelo y los valores reales u observados

* MAE (Error absoluto medio): mide la magnitud promedio de los errores en un conjunto de predicciones o mediciones

```
Zonas de clima distintas en entrenamiento: 23
         set             modelo  RMSE_azar  MAE_azar  R2_azar  RMSE_grupo  R2_grupo
           - Ingenuo (promedio)      0.851     0.754   -0.046       0.950    -1.386
A_clima_topo              Ridge      0.557     0.435    0.541       0.664    -0.179
A_clima_topo       RandomForest      0.555     0.419    0.545       0.843    -0.912
  B_satelite              Ridge      0.677     0.545    0.329       0.719    -0.409
  B_satelite       RandomForest      0.676     0.524    0.329       0.760    -0.633
    C_todo_9              Ridge      0.553     0.421    0.545       0.635    -0.055
    C_todo_9       RandomForest      0.555     0.415    0.545       0.880    -1.087
  D_reducido              Ridge      0.565     0.432    0.528       0.638    -0.041
  D_reducido       RandomForest      0.553     0.415    0.547       0.867    -0.910
```

Interpretación:

1. Como el dataset es reducido, un modelo más simple como **Ridge le gana** a random forest, más en zonas nuevas. En validación aleatoria empatan (0.553 vs 0.555). En la agrupada, Random Forest sube 0.84, mientras que Ridge se queda en 0.64. Por qué? Puede ser porque el clima solo toma 23 valores distintos, los árboles (300) memorizan por zona y no saben qué hacer con una zona que no vieron
2. El satélite aporta con el clima, aunque sea poquito. En validación aleatoria, agregar el satélite casi no mejora (0.557 a 0.553). En zonas nuevas sí ayuda un poco (0.664 a 0.635).
3. C y D casi empatan, se pueden quedar las 9 variables

DIAGNÓSTICO DE LA ESTRUCTURA POR ZONAS

Tenemos 23 zonas, estas validaciones solo cuentan si las parcelas de entrenamiento comparten zonas con las de predicción.

1. ¿Las 59 parcelas de predicción caen en zonas con datos de entrenamiento?
2. ¿Cuánto del rendimiento se explica solo con "saber la zona"? Si casi todo, el modelo es casi como una tabla de promedios por zona.
3. ¿Dentro de una misma zona, qué variables distinguen parcelas buenas de malas?

Para ver si vale la pena mejorar features satelitales (las que varían por zona) o si ya así nos quedamos.

Resultados:

```
Predicción en zona con entrenamiento: 57 de 59
Parcelas de entrenamiento por zona (para las de predicción):
count    57.0
mean     19.7
std      14.2
min       1.0
25%       6.0
50%      15.0
75%      34.0
max      34.0
Name: zona, dtype: float64
RMSE usando solo el promedio de la zona: 0.519 (parcelas evaluadas: 129)
RMSE ingenuo en esas mismas parcelas:    0.856
Correlación dentro de zona con el rendimiento:
AREA_HA           -0.15
elevacion_m        0.08
pendiente_grados   0.23
ndvi_may_jun       0.06
```

Interpretación:

1. 57 de las 59 parcelas de predicción caen en zonas que sí tienen parcelas de entrenamiento. Sí usamos aleatorio (las parcelas de una misma zona de clima quedan mezcladas)
2. "saber la zona" explica casi todo lo que explica el modelo. El promedio de las otras parcelas de la zona da un error de 0.519 t/ha, contra 0.856 del ingenuo. Ridge daba 0.553. En la práctica, el modelo es una tabla de promedios por zona, suavizada por el clima.
3. Dentro de una zona casi no hay señal en las features que construimos, correlaciones menores a ~0.17 en valor absoluto no se distinguen del ruido. Ahora vemos que satelital “ayudaba” en zonas nuevas, porque en realidad ayuda a distinguir entre zonas
4. Podemos aspirar a un RMSE de aproximadamente 0.5. Con una mejora xd de usar más la zona de forma directa.

MODELO HÍBRIDO POR ZONA

Una zona con 2 parcelas tiene un promedio poco confiable (ya vimos que las de predicción si llegan a compartir 0 y 1), y una con 34 es muy confiable. El promedio debe "confiar" más en las zonas con más datos.

Vamos a comparar tres modelos:

- Ridge C (pasado, referencia).
- Zona suavizada: el promedio de la zona se mezcla con el promedio global, con peso k (como si la zona tuviera k parcelas imaginarias con el promedio general). Si la zona no tiene parcelas de entrenamiento, se usa Ridge.
- Zona suavizada + ajuste por parcela: a lo anterior se le suma un pequeño Ridge que aprende lo que queda dentro de la zona (pendiente, área, NDVI).

Resultado:

```
1 Ridge C              (np.float64(0.553), np.float64(0.421))
2 Zona suavizada k=1    (np.float64(0.543), np.float64(0.391))
3 Zona + ajuste  k=1    (np.float64(0.534), np.float64(0.393))
2 Zona suavizada k=3    (np.float64(0.577), np.float64(0.434))
3 Zona + ajuste  k=3    (np.float64(0.541), np.float64(0.401))
2 Zona suavizada k=5    (np.float64(0.602), np.float64(0.464))
3 Zona + ajuste  k=5    (np.float64(0.548), np.float64(0.411))
```

Modelo	RMSE	MAE
1 Ridge C (referencia)	0.553	0.421
2 Zona suavizada, k=1	0.543	**0.391**
3 Zona + ajuste, k=1	**0.534**	0.393

Interpretación:

1. Mejora real pero pequeña, se cumple el max esperado de RMSE 0.5
2. Al subir k el modelo empeora = mezclar promedio global con promedio de zona daña modelo, confirma que zona importa.
3. Modelos 2 y 3 no cambian tanto. Mejor quedarnos con 2 porque es más simple y mejor rendimiento,

   Nuestra Predicción va a ser = promedio del rendimiento de las parcelas de entrenamiento de la misma zona de clima (con un suavizado mínimo hacia el promedio general). Si la zona no tiene parcelas de entrenamiento, se usa Ridge C como respaldo.

   MODELO FINAL Y PREDICCIONES

   Toca: Entrenar modelo con las 138 parcelas de entrenamiento

   Para qué?

1. Predicciones de las 59 parcelas PREDICCION
2. Guardar modelo que podamos usar en la visualización web

   Desempeño esperado: Error esperado: ~0.4 t/ha en promedio (MAE) y ~0.54 en RMSE, con R^2 de ~0.55 frente al 0 del modelo ingenuo. Aplica si las parcelas de predicción se parecen a las de entrenamiento en zona (caso del 97%). Para parcelas en zonas nuevas, el error esperado sube a ~0.64 con Ridge

Resultados:

```
ID_POLIGONO,rendimiento_pred_t_ha,metodo,n_train_zona
AGC_003,3.25,promedio_zona,6
AGC_011,4.58,promedio_zona,34
AGC_016,4.37,promedio_zona,34
AGC_025,3.03,promedio_zona,15
AGC_027,3.03,promedio_zona,15
AGC_028,4.37,promedio_zona,34
AGC_029,3.49,promedio_zona,2
AGC_030,3.31,promedio_zona,7
AGC_031,4.37,promedio_zona,34
AGC_036,4.37,promedio_zona,34
AGC_039,3.11,promedio_zona,8
AGC_042,3.25,promedio_zona,6
AGC_043,4.37,promedio_zona,34
AGC_050,3.11,promedio_zona,8
AGC_052,4.41,promedio_zona,3
AGC_061,3.32,promedio_zona,2
AGC_063,4.37,promedio_zona,34
AGC_065,4.2,promedio_zona,1
AGC_071,3.03,promedio_zona,15
AGC_075,3.03,promedio_zona,15
AGC_076,4.37,promedio_zona,34
AGC_082,4.32,promedio_zona,5
AGC_085,4.37,promedio_zona,34
AGC_086,3.03,promedio_zona,15
AGC_087,3.23,promedio_zona,1
AGC_088,4.58,promedio_zona,34
AGC_091,4.58,promedio_zona,34
AGC_093,3.03,promedio_zona,15
AGC_094,4.58,promedio_zona,34
AGC_095,4.37,promedio_zona,34
```

```
AGC_107,4.32,promedio_zona,5
AGC_113,3.25,promedio_zona,6
AGC_116,4.32,promedio_zona,5
AGC_118,3.48,promedio_zona,1
AGC_120,3.23,promedio_zona,1
AGC_126,4.58,promedio_zona,34
AGC_128,4.32,promedio_zona,5
AGC_129,3.25,promedio_zona,6
AGC_130,4.41,promedio_zona,3
AGC_136,4.37,promedio_zona,34
AGC_142,4.58,promedio_zona,34
AGC_143,4.37,promedio_zona,34
AGC_147,2.96,ridge_respaldo,0
AGC_149,4.41,promedio_zona,3
AGC_153,4.37,promedio_zona,34
AGC_154,4.37,promedio_zona,34
AGC_156,3.31,promedio_zona,7
AGC_158,4.37,promedio_zona,34
AGC_173,3.11,promedio_zona,8
AGC_174,4.11,ridge_respaldo,0
AGC_175,4.58,promedio_zona,34
AGC_177,4.37,promedio_zona,34
AGC_182,4.17,promedio_zona,1
AGC_183,3.03,promedio_zona,15
AGC_186,4.37,promedio_zona,34
AGC_188,4.58,promedio_zona,34
AGC_190,4.58,promedio_zona,34
AGC_191,4.37,promedio_zona,34
AGC_192,4.58,promedio_zona,34
```

```
Filas de salida: 59 (esperado 59)
Nulos en predicciones: 0 (esperado 0)

Metodo usado:
metodo
promedio_zona     57
ridge_respaldo     2
Name: count, dtype: int64

Predicciones (59 parcelas):
count    59.00
mean      3.95
std       0.62
min       2.96
25%       3.25
50%       4.37
75%       4.37
max       4.58
Name: rendimiento_pred_t_ha, dtype: float64
```

```
Rendimiento real, entrenamiento (138 parcelas):
count    138.00
mean       3.96
std        0.85
min        2.00
25%        3.20
50%        4.34
75%        4.55
max        5.59
Name: RENDIMIENTO_T_HA, dtype: float64

Parcelas con respaldo Ridge o zona de 1 sola parcela:
ID_POLIGONO  rendimiento_pred_t_ha         metodo  n_train_zona
    AGC_065                  4.20  promedio_zona             1
    AGC_087                  3.23  promedio_zona             1
    AGC_118                  3.48  promedio_zona             1
    AGC_120                  3.23  promedio_zona             1
    AGC_147                  2.96 ridge_respaldo             0
    AGC_174                  4.11 ridge_respaldo             0
    AGC_182                  4.17  promedio_zona             1
```

Interpretación:

1. El promedio predicho (3.95) casi coincide con el real de entrenamiento (3.96), y todas las predicciones caen dentro del rango razonable 2.96-4.58
2. Las predicciones son más agrupadas que la realidad (desviación 0.62 contra 0.85)
3. Muchas parcelas de predicción están en la misma zona grande (34 parcelas de entrenamiento) y reciben el mismo valor. Esto es una limitación real que se debe mencionar.
4. 7 parcelas poco confiables

Uso de la ciencia de datos en la inclusión financiera del sector agro

La ciencia de datos impulsa la inclusión financiera en el sector agropecuario, permite transformar información agrícola, climática y satelital en indicadores útiles para la toma de decisiones. Uno de los principales obstáculos para que los pequeños productores accedan al crédito es la falta de información sobre su actividad productiva, sus riesgos y su capacidad de generar ingresos. La Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO, 2018) señala que el uso de imágenes satelitales, datos complementarios y algoritmos de aprendizaje automático pueden contribuir a reducir esta asimetría de información, al facilitar la evaluación del estado de los cultivos y de la viabilidad de las unidades agrícolas.
Estos modelos predictivos estiman el rendimiento de los cultivos a partir de variables como los índices de vegetación, la precipitación y la temperatura. Esta información puede ayudar a las instituciones a evaluar los riesgos asociados con la producción agrícola, identificar parcelas con diferentes niveles de vulnerabilidad y diseñar productos financieros más adecuados para las necesidades de los productores, reduciendo los costos y el tiempo necesarios para recopilar información de campo. (Banco Mundial, 2019).

En México, esta aplicación se relaciona con los objetivos de los Fideicomisos Instituidos en Relación con la Agricultura (FIRA), ampliando el acceso al financiamiento formal y reduciendo las barreras que enfrentan los productores agropecuarios. En el caso de la cebada cultivada en Hidalgo, Tlaxcala y Puebla, desarrollar un modelo que estime el rendimiento por parcela podría proporcionar información adicional para la evaluación del riesgo productivo (FIRA, s. f.).

El desarrollo de un modelo para predecir el rendimiento de la cebada no solo tiene una aplicación tecnológica, sino también una posible contribución económica y social, la herramienta podría facilitar la evaluación de riesgos, apoyar el diseño de créditos y seguros agrícolas y favorecer decisiones financieras mejor fundamentadas.

Conclusiones

Bibliografía

- Breiman, L. (2001). Random forests. Machine learning, 45(1), 5-32. https://link.springer.com/article/10.1023/a:1010933404324
- Driving Financial Inclusion for Smallholder Farmers by Leveraging Satellite Data and Machine Learning | e-Agriculture | Food and Agriculture Organization of the United Nations.(s.f.) https://www.fao.org/e-agriculture/activity/webinar/driving-financial-inclusion-smallholder-farmers-leveraging-satellite-data-and
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. Technometrics, 12(1), 55-67. https://www.tandfonline.com/doi/abs/10.1080/00401706.1970.10488634
- Instituto Nacional de Estadística y Geografía. (2025). Continuo de Elevaciones Mexicano 4.0 (CEM 4.0). INEGI.
- Ncr, P. C., Ncr, R. K., Spss, J. C., Spss, T. K., Daimlerchrysler, T. R., & Daimlerchrysler, R. W. (1999). The CRISP-DM Process Model. no. C. https://public.dhe.ibm.com/software/analytics/spss/documentation/modeler/14.2/es/CRISP-DM.pdf
- *Portal FIRA*. (2024, 3 septiembre). Apoyos Para el Fomento. https://www.fira.gob.mx/Nd/ApoyosFomento.jsp
- World Bank. (2019). The digital financial services for agriculture handbook. https://documents1.worldbank.org/curated/en/394511624511863146/pdf/Digital-Credit-for-Smallholder-Farmers-Lessons-Learned-from-the-Field.pdf