Introducción

El sector agroalimentario en México enfrenta desafíos estructurales de gran magnitud, entre los cuales destacan la variabilidad climática global, las alteraciones drásticas en los patrones hídricos y térmicos estacionales, así como los márgenes de productividad cada vez más ajustados que ponen en riesgo la estabilidad de los productores. En cultivos destinados al sector alimentario y la economía regional, como la cebada cultivada en los estados de Hidalgo, Tlaxcala y Puebla, la falta de información oportuna, transparente y verificable sobre el rendimiento real de las cosechas representa uno de los principales obstáculos operativos y comerciales. Esta brecha de información impacta de manera directa y negativa en la inclusión financiera de la población rural, ya que restringe la capacidad de las instituciones de banca de desarrollo, comercial y las empresas aseguradoras para evaluar los riesgos agropecuarios, encareciendo el acceso a servicios financieros adaptados a la realidad productiva de cada región agrícola.

Frente a esta problemática, la iniciativa promovida por los Fideicomisos Instituidos en Relación con la Agricultura (FIRA) a través del programa de Apoyo a la Innovación Tecnológica en el marco de la Industria 4.0, impulsa la adopción de herramientas avanzadas de observación remota y ciencia de datos aplicada al campo. Las plataformas actuales proporcionan observaciones multiespectrales frecuentes, estandarizadas y de gran cobertura espacial, permitiendo monitorear de manera continua el desarrollo de la biomasa agrícola en tiempo real. No obstante el verdadero valor estratégico de estas tecnologías no reside únicamente en la adquisición masiva de imágenes, sino en la capacidad para desarrollar modelos analiticos e inteligencias predivtivas capaces de traducir series temporales de índices vegetativos, regímenes de precipitación y temperaturas en estimaciones cuantitativas altamente confiables del rendimiento por hectárea antes del periodo de cosecha.

El presente reporte técnico documenta de manera detallada y exhaustiva el proceso de diseño, validación y despliegue del modelo predictivo desarrollado en el marco del Reto AgroCebada 2026. A partir de un conjunto de datos integrados de 197 parcelas agrícolas, compuesto por 138 parcelas de entrenamiento y 59 parcelas reservadas exclusivamente para la evaluación, se diseñó un enfoque analítico híbrido e innovador que fusiona la zonificación agroclimática con técnicas de regresión lineal regularizada. El objetivo central de esta solución integral es mitigar eficazmente la asimetría informativa en toda la cadena de valor agrícola, proveyendo un instrumento cuantitativo robusto, auditable y listo para su integración en herramientas tecnológicas operativas y tableros web de consulta interactiva que beneficien directamente tanto a los pequeños productores como a los tomadores de decisiones estratégicas del sector agropecuario nacional.

Justificación

La disponibilidad masiva de datos procedentes de satélites y de estudios medioambientales ofrece una oportunidad real para transformar la gestión del rendimiento agrícola del campo mexicano. No obstante, para que este tipo de herramientas aporten valor, deben complementarse con modelos confiables que permitan extraer conclusiones fiables a partir de grandes volúmenes de datos disponibles.

El sector de la cebada en Hidalgo, Tlaxcala y Puebla, podría ser uno de los primeros en beneficiarse de esta previsibilidad. Ya que los rendimientos previsibles constituyen un

instrumento poderoso para los bancos de desarrollo rural, y FIRA desempeña un papel de liderazgo hacia la reducción de la asimetría de información que afecta actualmente a este sector.

Objetivo general

Desarrollar un modelo analítico, basado en técnicas de Aprendizaje Automático, capaz de predecir en tiempo real el rendimiento agrícola de las parcelas de cebada en los estados de Hidalgo, Tlaxcala y Puebla utilizando datos normales y de percepción remota sobre el estado de la vegetación, e integrarlo en una herramienta tecnológica operativa que permita su observación y consulta.

Objetivos específicos

- Realizar un análisis exploratorio de las variables disponibles (índice de vegetación, precipitaciones, temperatura y rendimiento observado) con el fin de detectar patrones y correlaciones clave.
- Entrenar y validar modelos predictivos (regresión lineal regularizada y algoritmos basados en árboles), seleccionando el mejor modelo mediante la comparación de sus estadísticos (RMSE, error absoluto medio, coeficiente de determinación, etc.) y predicción del rendimiento de las parcelas cuyos datos se han reservado para las pruebas de evaluación (30 % de las parcelas) utilizando el mejor modelo.
- Diseñar y desarrollar una aplicación o página web para consultar y visualizar los resultados de las predicciones por parcela.

Metodología

El desarrollo siguió el marco CRISP-DM (Chapman et al., 1999), organizando el proyecto en seis fases iterativas, descritas a continuación.

I. Comprensión del problema

El objetivo fue estimar el rendimiento de cebada (t/ha) de 59 parcelas, usando 138 parcelas con rendimiento conocido del ciclo abril-octubre de 2025, por lo que el análisis se limitó a ese periodo de tiempo. Además, se priorizó un modelo explicable y reproducible para la resolución del problema.

II. Comprensión de los datos

El entrenamiento del modelo y la creación de variables se limitó únicamente a los datos incluídos en los datasets otorgados por *FIRA*. Se integraron imágenes del satélite Planet (2025; NDVI, EVI, LAI y MSAVI), precipitación mensual de CHIRPS, temperaturas mínima y máxima de CHIRTS-ERA5, y elevación y pendiente (INEGI, 2025).

El máximo de los índices de vegetación correlacionó débil y negativamente con el rendimiento (r entre −0.17 y −0.26). El clima mostró asociaciones más fuertes: temperatura mínima (r = 0.60), precipitación (r = −0.46) y temperatura máxima (r = −0.29); la topografía alcanzó r = 0.29 y el área de la parcela no mostró relación.

III. Preparación de los datos

Se excluyeron las observaciones satelitales con más de 10% de nubosidad (conservando 31,708 de 47,804 registros). El clima se resumió para el ciclo (abril a octubre de 2025) y la topografía se extrajo por parcela. Dado que el máximo del índice resultó poco informativo, el NDVI se agregó por etapas fenológicas, además de la caída entre el máximo y octubre como indicadores de senescencia. Se descartaron variables redundantes o no discriminantes, como el día de arranque, la amplitud térmica, EVI, LAI y MSAVI, con lo que resultó una fila por parcela y nueve variables candidatas.

Feature	**Correlación con rendimiento**
tmin_ciclo	+0.60
prec_ciclo_mm	-0.46
tmax_ciclo	-0.29
elevacion_m	+0.29
pendiente_grados	+0.29
ndvi_may_jun	+0.53
ndvi_jul_sep	-0.28
ndvi_oct	+0.41
caida_pico_oct	-0.50

IV. Modelado

Se compararon un modelo ingenuo (promedio), la regresión Ridge (Hoerl y Kennard, 1970), que penaliza coeficientes extremos ante variables correlacionadas, y Random Forest (Breiman, 2001), con cuatro combinaciones de variables. La evaluación empleó validación cruzada (cinco particiones, tres repeticiones) y otra agrupada por zona de clima, que estima el desempeño en ubicaciones no observadas. Ridge igualó a Random Forest en la primera (error cuadrático medio, RMSE, de 0.55 t/ha), y generalizó mejor en zonas nuevas (0.64 frente a 0.88), por lo que se descartó este último.

El análisis reveló que las parcelas de entrenamiento se agrupan en solo 23 zonas de clima, pues varias comparten un píxel de ~5 km, y que estas zonas explican gran parte de la variación: el promedio de las demás parcelas de una zona alcanzó un error de 0.52 t/ha, mientras que, dentro de cada zona, los índices satelitales apenas se correlacionaron con el rendimiento. Este hallazgo motivó a una nueva iteración de comprensión de los datos, y adoptar un modelo híbrido: la predicción es el promedio del rendimiento de las parcelas de entrenamiento de la misma zona, suavizado hacia el promedio general, y, si la zona carece de datos, se emplea Ridge con las nueve variables. Una variante de ajuste adicional por parcela mejoró el error 0.01 t/ha, diferencia no distinguible del ruido, por lo que se prefirió la más simple.

V. Evaluación

El modelo final obtuvo un RMSE de 0.54 t/ha y un error absoluto medio de 0.39 t/ha en validación cruzada, frente a 0.85 t/ha del modelo ingenuo. De las 59 parcelas, 57 pertenecen a zonas con datos de entrenamiento y 2 recurren al respaldo Ridge; 7 (incluídas las Ridge) tienen baja confiabilidad por contar con una o ninguna parcela de entrenamiento en su zona. Entre estas limitaciones destacan el uso de un solo ciclo agrícola, que impide capturar variabilidad entre años; que parcelas de una misma zona reciben la misma predicción; y que, al elegir entre alternativas con los mismos datos, el error real podría superar al estimado. Las relaciones halladas son asociaciones, no causales.

VI. Despliegue

Se generó el archivo de predicciones, indicando el método y las parcelas de entrenamiento que respaldan cada estimación, y se guardó el modelo en su respectivo joblib.

Resultados y discusión

El análisis de las 197 parcelas agrícolas permitió identificar de manera extensa las relaciones que tienen las condiciones climáticas, las características de la vegetación y el rendimiento de la cebada durante los ciclos presentados. Para garantizar la calidad de la información proporcionada por el modelo, se aplicó un filtro de nubosidad menor o igual a 10% reduciendo así los registros a 31,708. Después de realizar este proceso las 197 parcelas conservaron las observaciones disponibles, permitiendo así integrar la información climática, topográfica y satelital para construir las bases de datos.

Entre las variables que se evaluaron dentro del análisis, la temperatura mínima del ciclo presentó la correlación positiva más significativa poseyendo una r=0.60, seguida por la variable NDVI con un r=0.53, con esto pudimos concluir que las parcelas con temperaturas mínimas más elevado y mayor vigor de vegetación durante las primeras etapas de su ciclo presentaban mejores rendimientos posteriormente. Por el contrario, la precipitación acumulada mostró tener una correlación negativa de r=-0.46 mientras que la caída del NDVI presentó una correlación de -0.50.

Con el objetivo de seleccionar el enfoque predictivo más adecuado, se compararon los modelos de regresión de Ridge, Random forest y un modelo de referencia basado en promedios. Al realizar la validación aleatoria, Ridge y Radmon Forest obtuvieron resultados similares presentando errores medios (RMSE) de aproximadamente 0.55 t/ha. Posteriormente al evaluar la capacidad de generalización que tenían dentro de las zonas climáticas no observadas, Ridge presentó un menor error, siendo este de 0.64 frente a 0.88 t/ha de Random Forest.

La siguiente parte del diagnóstico mostró que las parcelas se distribuyen dentro de 23 zonas climáticas relevantes y que cada una de estas influenciaron de gran manera las diferencias presentes dentro del rendimiento de cada una de ellas. El promedio de rendimiento de parcelas de una misma zona alcanzó un RSME de 0.52 t/ha, mostrando un mejor resultado que Ridge con 0.55 t/ha y que el modelo de referencia con un 0.85 t/ha. Además, se identificó que las variables satelitales presentaron una capacidad limitada para

distinguir las diferencias de rendimiento que presentaban las parcelas que estaban ubicadas dentro de una misma zona, indicando que las variaciones presentes dentro de las parcelas estaban más arraigadas a las diferencias climaticas y geograficas que a las ligeras variaciones individuales de cada una de las parcelas.

Con todos estos hallazgos, se desarrolló un modelo híbrido que utiliza el promedio de rendimiento de las parcelas dentro de cada zona climática junto con un ajuste mínimo hacia el promedio general. En el caso de que una parcela pertenezca a una zona sin datos de entrenamiento, se utilizará el modelo de Rigde como método alternativo por la gran efectividad que mostró previamente. También se consideró la incorporación de un ajuste adicional mediante las variables de cada parcela, sin embargo la mejora que se obtuvo a partir de este método fue de apenas 0.01 t/ha, no siendo lo suficientemente significativo como para aumentar la complejidad del modelo.

El modelo final se entrenó con las 138 parcelas con el objetivo de generar las predicciones de rendimiento de las 59 restantes. Durante la validación cruzada, se obtuvo un error absoluto medio (MAE) de 0.39 t/ha, un RMSE de 0.54 t/ha y un coeficiente de determinación (R^2) de 0.55, frente a un valor de referencia de cero para el modelo ingenuo. Estos resultados muestran una mejoría con respecto al modelo de referencia y dan garantía de la utilidad del enfoque que fue seleccionado. El promedio del rendimiento predicho fue de 3.95 t/ha, siendo este muy cercano a el rendimiento promedio de 3.96 t/ha en las parcelas de entrenamiento, sin embargo esta similitud en los resultados no garantiza la precisión de las predicciones.

Algunas de las principales limitaciones que se identificaron fueron que 57 de las 59 parcelas a predecir pertenecían a zonas climáticas con información de entrenamiento. Dentro de este grupo 7 de las parcelas fueron clasificadas como poco confiables debido a la escasez de parcelas dentro de sus respectivas zonas. Además, las predicciones presentaron una menor variabilidad que los rendimientos presentes dentro de las parcelas reales junto con que varias parcelas recibieron un valor muy similar por compartir las zonas con muchos registros previamente presentes.

Con todo esto en consideración, los resultados que hacen uso de la información climática, topográfica y satelital permitieron desarrollar predicciones valiosas para el rendimiento de cada parcela. El modelo final ofrece una alternativa realmente sencilla y fácilmente entendible para la evaluación del riesgo productivo y aportar información para la realización de decisiones financieras y de inversión a largo plazo.

Uso de la ciencia de datos en la inclusión financiera del sector agro

La ciencia de datos impulsa la inclusión financiera en el sector agropecuario, permite transformar información agrícola, climática y satelital en indicadores útiles para la toma de decisiones. Uno de los principales obstáculos para que los pequeños productores accedan al crédito es la falta de información sobre su actividad productiva, sus riesgos y su capacidad de generar ingresos. La Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO, 2018) señala que el uso de imágenes satelitales, datos

complementarios y algoritmos de aprendizaje automático pueden contribuir a reducir esta asimetría de información, al facilitar la evaluación del estado de los cultivos y de la viabilidad de las unidades agrícolas.
Estos modelos predictivos estiman el rendimiento de los cultivos a partir de variables como los índices de vegetación, la precipitación y la temperatura. Esta información puede ayudar a las instituciones a evaluar los riesgos asociados con la producción agrícola, identificar parcelas con diferentes niveles de vulnerabilidad y diseñar productos financieros más adecuados para las necesidades de los productores, reduciendo los costos y el tiempo necesarios para recopilar información de campo. (Banco Mundial, 2019).

En México, esta aplicación se relaciona con los objetivos de los Fideicomisos Instituidos en Relación con la Agricultura (FIRA), ampliando el acceso al financiamiento formal y reduciendo las barreras que enfrentan los productores agropecuarios. En el caso de la cebada cultivada en Hidalgo, Tlaxcala y Puebla, desarrollar un modelo que estime el rendimiento por parcela podría proporcionar información adicional para la evaluación del riesgo productivo (FIRA, s. f.).

El desarrollo de un modelo para predecir el rendimiento de la cebada no solo tiene una aplicación tecnológica, sino también una posible contribución económica y social, la herramienta podría facilitar la evaluación de riesgos, apoyar el diseño de créditos y seguros agrícolas y favorecer decisiones financieras mejor fundamentadas.

Conclusiones

El desarrollo e implementación del modelo predictivo para el Reto AgroCebada 2026 permitió cumplir con los objetivos planteados, demostrando de manera categórica que la integración inteligente de la zonificación agroclimática y las técnicas de regresión lineal regularizada constituye una estrategia sumamente efectiva para estimar el rendimiento de la cebada en los estados de Hidalgo, Tlaxcala y Puebla. Través del análisis riguroso de las 197 parcelas agrícolas disponibles, se comprobó que el enfoque híbrido zonal suavizado supera ampliamente a los modelos no lineales basados en árboles al evitar el sobreajuste espacial en zonas no observadas, logrando consolidar un error absoluto medio (MAE) a 0.39 t/ha y un RMSE de 0.54 t/ha. Estos resultados reducen significativamente el error en comparación directa con el modelo de referencia, ofreciendo estimaciones estables, auditables y estadísticamente coherentes con la realidad productiva regional.
La ejecución sobre las 59 parcelas de evaluación confirmó la solidez operativa del sistema: el 96.6% de las estimaciones se apoyó en promedios zonales ponderados, mientras que las escasas zonas sin antecedentes históricos fueron resueltas con éxito mediante el algoritmo Ridge de respaldo: No obstante, el estudio permitió identificar limitaciones metodológicas de gran relevancia, tales como la dependencia exclusiva de un único ciclo agrícola que impide capturar la variabilidad interanual de las cosechas, la uniformidad matemática en las predicciones para las parcelas dentro de una misma zona climática amplia, y la presencia de baja confiabilidad en polígonos con un respaldo muestral reducido,. Estas observaciones técnicas confirman prudentemente que las correlaciones halladas representan asociaciones estadísticas basadas en percepción remota y no vínculos causales directos de manejo agronómico.

Para terminar, este esfuerzo técnico e interdisciplinario trasciende el ámbito algorítmico al demostrar el profundo potencial transformador de la ciencia de datos en la inclusión financiera del sector agropecuario mexicano. Al mitigar la brecha informativa mediante observaciones satelitales multiespectral, se dota de las instituciones financieras, a la banca de desarrollo y a FIRA de un activo cuantitativo confiable para la toma de decisiones, facilitando la evaluación objetiva del riesgo crediticio, el diseño de financiamiento y la creación de seguros paramétricos orientados a respaldar a los pequeños productores.

Bibliografía

- Breiman, L. (2001). Random forests. Machine learning, 45(1), 5-32. https://link.springer.com/article/10.1023/a:1010933404324
- Driving Financial Inclusion for Smallholder Farmers by Leveraging Satellite Data and Machine Learning | e-Agriculture | Food and Agriculture Organization of the United Nations.(s.f.) https://www.fao.org/e-agriculture/activity/webinar/driving-financial-inclusion-smallholder-farmers-leveraging-satellite-data-and
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. Technometrics, 12(1), 55-67. https://www.tandfonline.com/doi/abs/10.1080/00401706.1970.10488634
- Instituto Nacional de Estadística y Geografía. (2025). Continuo de Elevaciones Mexicano 4.0 (CEM 4.0). INEGI.
- Ncr, P. C., Ncr, R. K., Spss, J. C., Spss, T. K., Daimlerchrysler, T. R., & Daimlerchrysler, R. W. (1999). The CRISP-DM Process Model. no. C. https://public.dhe.ibm.com/software/analytics/spss/documentation/modeler/14.2/es/CRISP-DM.pdf
- *Portal FIRA*. (2024, 3 septiembre). Apoyos Para el Fomento. https://www.fira.gob.mx/Nd/ApoyosFomento.jsp

- World Bank. (2019). The digital financial services for agriculture handbook. https://documents1.worldbank.org/curated/en/394511624511863146/pdf/Digital-Credit-for-Smallholder-Farmers-Lessons-Learned-from-the-Field.pdf